

Lab 3 - Fine-Tuning vs. From-Scratch Training for Text Classification

Autor: Bartosz Gacek

Wstęp

Podobnie jak w poprzednich laboratoriach, proces trenowania modeli został przeprowadzony przy użyciu platformy `Runpod`. Konfiguracja sprzętowa pozostała bez zmian i obejmowała:

- GPU: `Nvidia A40`
 - Pamięć RAM: 48 GB
 - CPU: 9 vCPU
-

Napotkane problemy i ich rozwiązanie

Pierwotna koncepcja zakładała wykorzystanie modelu `GPT2ForSequenceClassification` jako bazy do fine-tuningu, wraz z kompatybilnym tokenizerem. Niestety, wyniki uzyskane po wytrenowaniu tego modelu okazały się niezadowalające i, co zaskakujące, gorsze od rezultatów osiągniętych przez prosty model transformera trenowany od zera. Stało to w sprzeczności z oczekiwaniami przedstawionymi w instrukcji laboratoryjnej.

Analiza problemu doprowadziła do wniosku, że przyczyną niepowodzenia był niewłaściwy dobór modelu bazowego. Model GPT-2 został wytrenowany głównie na korpusach języka angielskiego, co sprawiło, że wzorce językowe, które przyswoił, nie miały bezpośredniego przełożenia na specyfikę języka polskiego, a w szczególności na polski slang młodzieżowy. Metoda fine-tuningu (w tym przypadku LoRA), modyfikująca jedynie niewielką część wag, okazała się niewystarczająca, aby model skutecznie nauczył się nowych, specyficznych dla języka polskiego zależności.

W związku z powyższym podjęto decyzję o zmianie modelu bazowego na model dedykowany dla języka polskiego – **Herbert** (`allegro/herbert-base-cased`). Decyzja ta okazała się trafna. Model ten osiągnął wyniki znacząco przewyższające poprzednie próby, deklasując również model trenowany od podstaw. Potwierdziło to kluczowe znaczenie doboru odpowiedniego modelu pre-trenowanego do języka docelowego zadania.

Opis zbioru danych

Do eksperymentów wybrano zbiór danych `jziebura/polish_youth_slang_classification`, dostępny na platformie Hugging Face. Jest to zbiór służący do klasyfikacji sentymentu tekstów zawierających polski slang młodzieżowy. W trakcie analizy danych potwierdzono, że kolumna "tekst" nie zawiera pustych wartości.

- **Zadanie:** Klasyfikacja tekstu (sentyment).
- **Liczba klas:** 3.
- **Podział danych:** Zbiór podzielony na zestawy treningowy, walidacyjny i testowy.
- **Liczebność zbioru testowego:** 543 próbki.

Dystrybucja klas (sentyment):

Klasa	Liczba próbek	Udział procentowy
0 (Negatywny)	1259	29.03%
1 (Neutralny)	2219	51.16%
2 (Pozytywny)	859	19.81%

Przykłady z datasetu:

1. - *Masz może lejsy, Damian?* - *Mam, ale ci nie dam, Furto!*
2. - *Siema mordo, skąd Gucio ma kase na te markowe ubrania?* - *Rzuca buchem od kilku tygodni.*
3. *Rano koniecznie jest z cytryną woda, bo wczoraj był lekki melanż*

Opis Modeli

W ramach laboratorium porównano dwa podejścia do treningu modeli językowych:

1. Model trenowany od zera (From-Scratch)

Mały model typu **Decoder-only Transformer** (architektura GPT), zainicjalizowany losowymi wagami.

- **Architektura:** GPTLanguageModel (własna implementacja).
- **Konfiguracja:**
 - `block_size` : 128
 - `n_embd` : 56
 - `n_head` : 4
 - `n_layer` : 6
 - `dropout` : 0.1
 - `n_classes` : 3
- **Rozmiar modelu:** ~3.04 mln parametrów (13.08 MB).
- **Tokenizer:** Wykorzystano tokenizer z modelu `allegro/herbert-base-cased`.
- **Trening:** 5 epok, learning rate 3e-4, batch size 8.

2. Model Fine-Tuned (LoRA)

Pretrenowany model `allegro/herbert-base-cased` (architektura BERT, Encoder-only), dostrojony do zadania klasyfikacji przy użyciu techniki **LoRA (Low-Rank Adaptation)**.

- **Model bazowy:** Herbert Base Cased (polski model językowy).
- **Metoda fine-tuningu:** LoRA (r=8, alpha=16, dropout=0.1). Pozwala to na trening jedynie niewielkiej liczby dodatkowych parametrów (adapterów), pozostawiając wagi modelu bazowego zamrożone.
- **Rozmiar modelu:** ~124.4 mln parametrów (474.73 MB).
- **Trening:** 5 epok, learning rate 2e-4, batch size 8.

Ewaluacja i Wyniki

Przebieg treningu


Poniżej przedstawiono wykresy z procesu uczenia obu modeli (zalogowane w Weights & Biases).

Legenda do wykresów:


- **Różowa linia:** *scratch polish* - Model from-scratch z tokenizerem Herbert (Główny model z raportu).

- **Pomarańczowa linia:** *lora herbert* - Model fine-tuned Herbert (LoRA) (Główny model z raportu).
- **Zielona linia:** *scratch p50k_base* - Model from-scratch z tokenizerem *p50k_base* (Eksperyment dodatkowy).
- **Niebieska linia:** *gpt2* - Model fine-tuned GPT-2 (Nieudana próba opisana w sekcji "Napotkane problemy").



Loss treningowy:




Dokładność (Accuracy) treningowa:



Metryki walidacyjne:





Wyniki końcowe na zbiorze testowym

Ewaluacja została przeprowadzona na wydzielonym zbiorze testowym (543 próbki). Poniższa tabela przedstawia zestawienie wyników obu modeli.

Metryka	Transformer (From-Scratch)	LoRA (Fine-Tuned Herbert)
Accuracy	0.5985	0.7145
F1 (macro)	0.4482	0.6901
F1 (weighted)	0.5023	0.7076
Inference time (całość)	0.27s	0.64s
Time per sample	0.49ms	1.18ms
Total parameters	3,036,603	124,445,187
Model size	13.08 MB	474.73 MB

Analiza Porównawcza i Wnioski

1. Jakość klasyfikacji (Accuracy & F1):

Model fine-tunowany (Herbert + LoRA) osiągnął znacząco lepsze wyniki (**71.45% accuracy**) w porównaniu do modelu trenowanego od zera (**59.85% accuracy**). Jeszcze większą różnicę widać w metryce F1 Macro (0.69 vs 0.45), co sugeruje, że Herbert lepiej radzi sobie z klasami rzadziej reprezentowanymi lub trudniejszymi przypadkami. Wynika to z faktu, że Herbert posiada już "wiedzę" o języku polskim zdobytą podczas pre-treningu na ogromnych korpusach, podczas gdy mały transformer musiał uczyć się wszystkiego od zera na stosunkowo niewielkim zbiorze danych slangu.

2. Efektywność obliczeniowa (Inference Time):

Model trenowany od zera jest **ponad 2-krotnie szybszy** w inferencji (0.49ms vs 1.18ms na próbkę). Wynika to bezpośrednio z jego rozmiaru – ma on ok. 3 mln parametrów, w przeciwieństwie do 124 mln

parametrów Herberta. Jest to klasyczny kompromis jakość vs szybkość/zasoby. Do prostych zastosowań, gdzie 60% skuteczności jest akceptowalne, mały model byłby znacznie tańszym rozwiązaniem.

3. **Stabilność treningu:**

Jak wspomniano w sekcji problemów, wybór odpowiedniego modelu bazowego jest kluczowy. GPT-2 (angielski) nie sprawdził się w zadaniu dla języka polskiego. Dopiero użycie polskiego modelu (Herbert) pozwoliło na skuteczne wykorzystanie transfer learningu. W krzywych lossu treningowego nie widać znaczących różnic między modelami. Różnica jest dopiero widoczna w metrykach na zbiorze walidacyjnym. Tutaj Herbert znacząco wyprzedził pozostałe rozwiązania.

Uwaga dotycząca liczby epok: Podczas wcześniejszych eksperymentów próbowano użyć większej liczby epok, jednak modele szybko zaczynały się przetrenowywać (overfitting). Z tego powodu trening został ograniczony do 5 epok. Wnioski o potencjalnych dalszych wzrostach dokładności wyciągane na podstawie trendów widocznych na wykresach mogą być zatem mylące, gdyż w rzeczywistości dłuższy trening prowadził do poprawy wyników jedynie na zbiorze treningowym.

4. **Podsumowanie:**

Eksperyment potwierdził przewagę fine-tuningu dużych modeli językowych nad trenowaniem małych modeli od zera w zadaniach NLP, szczególnie gdy dysponujemy ograniczonym zbiorem danych treningowych. Modele pre-trenowane oferują lepszą generalizację i rozumienie kontekstu językowego. Jednakże, małe dedykowane modele nadal mają swoje miejsce w systemach wymagających bardzo niskiej latencji lub działających na urządzeniach o ograniczonych zasobach, o ile akceptujemy niższą jakość predykcji.